

Previsão de Diabetes com SVM e Redes Neurais

Trabalho Final — Disciplina de Inteligência Artificial

Integrantes

- Caio Carneiro Germani · RA: 23155074-2
- Pedro Henrique dos Santos Manfrim · RA: 23079481-2
- Daniel Rodrigues Nardi · RA: 23159251-2
- Eduardo Escudeiro Seifert · RA: 23034738-2

1. Contextualização e Problema

O diabetes mellitus é uma das doenças crônicas de maior prevalência mundial, afetando centenas de milhões de pessoas. O diagnóstico precoce é essencial para evitar complicações como doenças cardiovasculares, insuficiência renal e neuropatias. Técnicas de Inteligência Artificial têm se mostrado eficazes no auxílio diagnóstico por meio da análise automatizada de dados clínicos.

Problema investigado: é possível prever, a partir de dados clínicos de uma paciente, se ela possui ou virá a desenvolver diabetes?

Hipótese: modelos de IA treinados com dados clínicos (glicose, IMC, idade, histórico familiar) são capazes de classificar pacientes diabéticas com acurácia superior a 70%, e a Rede Neural tende a superar o SVM por maior capacidade de aprender padrões não-lineares.

2. Dataset

Foi utilizado o **Pima Indians Diabetes Dataset**, disponível publicamente no UCI Machine Learning Repository. O dataset contém 768 amostras de pacientes do sexo feminino com idade mínima de 21 anos, da etnia Pima (nativa americana), grupo com alta prevalência de diabetes.

Atributos do dataset:

Atributo	Descrição	Tipo
Gravidez	Número de gestações	Inteiro
GlicosePlasmatica	Concentração de glicose no plasma (mg/dL)	Inteiro
PressaoArterial	Pressão diastólica (mm Hg)	Inteiro
EspessuraPele	Espessura dobra cutânea (mm)	Inteiro
Insulina	Nível de insulina sérica (μU/ml)	Inteiro
IMC	Índice de Massa Corporal (kg/m²)	Float
FuncaoPedigree	Função de histórico familiar de diabetes	Float
Idade	Idade em anos	Inteiro
Diabetes (alvo)	0 = não diabética / 1 = diabética	Binário

Preparação dos dados: valores zerados em colunas clínicas (glicose, pressão, IMC, etc.) foram substituídos pela mediana da coluna, pois zero é biologicamente inválido. A divisão foi 80% treino / 20% teste com estratificação. Os dados foram normalizados com StandardScaler (média 0, desvio padrão 1) antes de alimentar os modelos.

3. Métodos de IA Utilizados

Parte 1 — SVM (Support Vector Machine)

O SVM é um algoritmo de aprendizado supervisionado que busca o hiperplano de máxima margem de separação entre as classes. Foi utilizado com kernel RBF (Radial Basis Function) para capturar relações não-lineares entre os atributos clínicos.

```
Parâmetros: kernel='rbf', C=10, gamma='scale'
```

Parte 2 — RNA / MLP (Rede Neural Artificial)

Rede neural do tipo Perceptron Multicamadas com duas camadas ocultas (64 e 32 neurônios), função de ativação ReLU e otimizador Adam. Treinada por 150 épocas.

```
Arquitetura: Input(8) → Dense(64, ReLU) → Dense(32, ReLU) → Output(sigmoid)
```

4. Avaliação dos Modelos

Métricas obtidas:

Métrica	SVM (Parte 1)	RNA (Parte 2)
Acurácia	71.43%	74.03%
Precisão	59.62%	65.22%
Revocação	57.41%	55.56%
F1-Score	58.49%	60.0%

Gráfico 1 — Comparação de Métricas:




Gráfico 2 — Matrizes de Confusão:




Gráfico 3 — Curva de Perda da RNA:





Gráfico 4 — Distribuição da Variável Alvo:



5. Comparação dos Resultados

A RNA obteve desempenho superior ao SVM em acurácia (74.03% vs 71.43%) e precisão (65.22% vs 59.62%), indicando que a estrutura de múltiplas camadas permitiu capturar padrões mais complexos nos dados clínicos. Ambos os modelos enfrentaram dificuldade com a classe positiva (diabéticas), reflexo do desbalanceamento do dataset (65%/35%). A revocação relativamente baixa (~55-57%) indica que há casos de diabetes não identificados — este ponto poderia ser melhorado com técnicas de balanceamento como SMOTE.

6. Conclusão

A hipótese foi confirmada: ambos os modelos atingiram acurácia superior a 70%, e a RNA superou o SVM em todas as métricas, conforme esperado. O projeto demonstrou na prática o pipeline completo de desenvolvimento de uma solução de IA: definição do problema, coleta e preparação dos dados, treinamento, avaliação com métricas e gráficos, e comparação entre modelos de paradigmas distintos (método clássico vs. rede neural).

A experiência revelou a importância do pré-processamento — sem o tratamento dos zeros inválidos, os modelos apresentaram desempenho significativamente inferior. Também ficou evidente que métricas complementares à acurácia (precisão, revocação, F1) são essenciais para avaliar modelos em datasets desbalanceados, especialmente em problemas médicos onde falsos negativos têm alto custo.